

Unity 16년, AI 모델을 앱 안에서 돌립니다.

신호정



AI 제품 엔지니어

Applying For :

AI Product Engineer / 온디바이스 AI 클라이언트 /
게임 AI
(시니어 개발자, 테크리드 겸임 가능)

Contact Me At :

Email seenjeonga@gmail.com
GitHub github.com/Yopkigom [확인하기](#)
Web prweb.yopkigom.workers.dev [확인하기](#)
Location 경기도

Introduction

실시간 클라이언트를 16년 만들어 온 개발자입니다.
지금은 AI 모델을 제품 안에서 돌아가게 만드는 일을 합니다.
소셜 아바타 앱 개발팀을 3년 4개월 이끌었고,
2026년 8월에는 두 팀 프로젝트를 동시에 테크리드로 맡아 둘 다 제출했습니다.

Experience

뉴냅스 개발팀 수석	발성 교정용 Unity 실시간 음성 녹음 모듈	2025.09 ~ 2026.01
일루니 개발팀장	소셜 아바타 앱 Moii, 주니어 4명 리딩, 누적 30만, 평점 4.3	2022.05 ~ 2025.08
캡케이크소프트 사원	영어 학습 앱, 32bit 온라인 앱의 64bit 오프라인 1인 전환	2020.06 ~ 2022.04
티쓰리엔터테인먼트 사원	영어 학습 앱 클라이언트 개발 특허 공동발명	2017.06 ~ 2020.06
네오위즈 게임온스튜디오 사원	시스타 카지노 한글화, 갑사 수순(포커) 클라이언트	2015.12 ~ 2017.01
중소 게임 개발사 사원	캐주얼, 리듬, 2D MO RPG 클라이언트	2009.10 ~ 2015.11

Awards & Patents

수상	제8회 K-디지털 트레이닝 해커톤 장려상(고용노동부장관상) 2026.09
특허	아바타 생성 장치 및 방법 KR 10-2652652 / KR 10-2876336 / US 12,223,576 B2 외국어 학습시스템 KR 10-2093938, 후속 출원 5건에 피인용
교육	동의대학교 게임공학 졸업 2010.03 코드잇 스프린트 AI 엔지니어 부트캠프 수료 2026.08

AI Projects

온디바이스 RAG	llama.cpp를 Unity에 직접 통합, ONNX FP16 임베딩 경량화, Galaxy S25 실기기 검증
모델 경량화	의료영상 분류 모델 INT8 3.64배 압축, ONNX 추론 2.15배 단축, 위음성 0 유지
광고 소재 생성	Tech Lead / OpenAPI 계약 모노레포, 광고 카피 가이드라인 위반 0건, 컷팅 165건 최다
재난 대피 안내	Tech Lead / 아키텍처와 HTTP 계약 소유 K-DT 해커톤 장려상(장관상) 수상
PR 사이트	Next.js + Cloudflare Workers, Ask AI 챗봇 Lighthouse 접근성 100

Tech Stack

Client / Real-time

C#	Unity	Unity Sentis
C/C++	IL2CPP AOT	
Android NDK	Agora	
실시간 오디오	MVP	

AI / Deployment

llama.cpp	ONNX	PyTorch
INT8 PTQ	RAG	LangGraph
TensorRT	TFLite	FastAPI
Cloudflare		

Overview

숫자로 보는 핵심 역량.
모든 수치의 근거와 맥락은 뒤쪽 상세 페이지에 있습니다.

Real-time Client

실시간 클라이언트 16년

캐주얼, 리듬 게임에서 소셜 아바타 앱, 디지털치료기기까지. 프레임 예산 안에서 무엇을 지킬지 정하는 일

16년

Unity 실시간 클라이언트 개발 경력

30fps

10인 이상 동시 참여 그룹 콘텐츠에서 평균 유지

18개 이상

동시에 조합하는 아바타 부위 수

3개월

12년 된 32bit 앱을 64bit로 1인 전환

Team Leading

개발팀장 3년 4개월

소셜 아바타 앱 Moii. 주니어 4명과 4개월 만에 프로토타입, 1년 만에 오픈 베타

30만

누적 다운로드

4.3/5.0

사용자 평점

4명

3년 4개월 리딩한 주니어 개발자

1년

오픈 베타까지, 4개월 만에 프로토타입

On-device AI

모델 경량화와 실기기 배포

의료영상 분류 모델 3종 포맷 변환, llama.cpp를 Unity에 직접 통합해 Galaxy S25에서 RAG 구동

3.64배

INT8 양자화 압축, 16.24MB에서 4.47MB

2.15배

ONNX 추론 지연 단축, 20.20ms에서 9.40ms

0건

위음성(FN), Recall 1.0 유지 검증

1.1GB

임베딩 모델 FP16 경량화, 2.2GB에서

Tech Lead

두 팀 프로젝트 동시 테크리드

2026년 8월, 광고 소재 생성 서비스와 재난 대피 안내 서비스를 동시에 이끌어 둘 다 제출

2팀

동시 테크리드, K-DT 해커톤 장려상(장관상)

165건

팀 커밋 최다, ADR 19건 작성

61%

팀 전체 커밋 약 270건 중 본인 비중

22회

모델 간 HTTP 계약 (openapi.yaml) 개정 소유

IP & Operations

지식재산과 개인 운영 자산

등록특허 국내 3건, 미국 1건. PR 사이트와 Ask AI 챗봇을 운영비 0원으로 운영 중

4건

등록특허, 국가연구개발사업 참여

5건

후속 출원에 피인용된 특허

100

Lighthouse 접근성, SEO 100, 성능 97 ~ 100

0.6초


Ask AI 챗봇 응답, 운영비 0원



브랜드 스타일 광고 소재 생성 서비스 테크리드, AI 생성/서빙 | 4인 | 2026.08

제품 사진, 제품명, 소구점으로 인스타그램용 만화형 6칸 광고 소재를 만드는 서비스. 1번 칸을 레퍼런스로 나머지 5칸을 병렬 생성해 3x2로 합성

저장소 확인하기



Unity 온디바이스 RAG

앱 개인 | 2026

llama.cpp를 Unity에 직접
통합해 Galaxy S25 실기기에서
연말정산 문서 질의응답을
구동하는 시연

동영상 보기



온디바이스 쇼핑물 리뷰

감성 분석 개인 | 2026

쇼핑물 리뷰로 학습한 한국어
감성 분류 모델을 ONNX로
변환해 Unity Sentis로 Android
앱에서 구동하는 시연

동영상 보기

AI 엔지니어 과정

K-DT, 두 팀 프로젝트 테크리드
2026.02 ~ 2026.09

- 코드잇 스프린트 AI 엔지니어 부트캠프 (K-DT 10기),
2026.02 ~ 2026.08 수료
- 2026년 8월 두 팀 프로젝트를 동시에 테크리드로 이끌어 둘 다 제출,
제8회 K-디지털 트레이닝 해커톤 장려상(고용노동부장관상) 수상
- Unity 온디바이스 RAG 앱, 의료영상 분류 모델 경량화,
온디바이스 감성 분석 앱을 개인 프로젝트로 수행. 상세는 AI Projects

뉴냅스

개발팀 수석
2025.09 ~ 2026.01

- 발성 교정용 디지털치료기기의 Unity 실시간 음성 녹음 모듈 개발.
실시간 음성 버퍼에 직접 접근해 청크 단위 녹음, dB 측정,
파형 출력으로 기능을 분리
- Android 음성 어시스턴트 호출 시 오디오 세션이 깨지는 문제를
OnAudioFilterRead 경로 대신 기본 Microphone 버퍼 접근으로 구조를
바꿔 해결
- 녹음 모듈을 별도 앱으로 분리해 음성 분석 모델을 맡은 AI 팀에 전달,
협업 인터페이스 확보
- 음성 모듈 설계 문서 작성과 규제 서류 대응
- 필드 테스트 이슈를 팀원에게 할당하고 관리해 2개월간 핫픽스 6회

일루니

개발팀장
2022.05 ~ 2025.08

- 소셜 아바타 앱 Moii 개발팀 리딩. 주니어 4명과 3년 4개월,
개발 4명으로 4개월 만에 프로토타입, 1년 만에 오픈 베타
- 누적 다운로드 30만, 사용자 평점 4.3 / 5.0,
주요 업데이트와 비정기 핫픽스 운영
- 아바타 순차 생성 최적화: 조합 부위 18개 이상,
10인 이상이 동시에 참여하는 그룹 콘텐츠에서 평균 30fps 이상 유지
- Agora 더블 버퍼링 녹음으로 렌더링 프레임을 지키면서
실시간 음성 전송과 녹음을 동시 처리
- MVP 프레임워크를 도입해 신규 기능 개발 절차를 표준화
- "아바타 생성 장치 및 방법" 특허 공동발명(5인).
과기정통부 실감콘텐츠핵심기술개발 과제
"문장으로부터의 3차원 동영상 자동 생성 기술" 참여

캡케이크소프트

티쓰리엔터테인먼트 자회사 | 사원
2020.06 ~ 2022.04

- 영어 학습 앱 개발
- 12년 된 32bit 온라인 앱 오잉글리시를
64bit 오프라인 반숙영어 앱으로
3개월 만에 1인 전환, 시리즈 4종을 1개월 간격으로 출시

티쓰리엔터테인먼트

오잉글리시팀 | 사원
2017.06 ~ 2020.06

- 영어 학습 앱 클라이언트 개발
- "학습자가 선택한 동영상을 학습 콘텐츠로 활용하는 외국어 학습시스템"
특허 공동발명(4인, KR 10-2093938). 후속 출원 5건에 피인용

네오위즈 게임온스튜디오

개발1실 | 사원
2015.12 ~ 2017.01

- 시스타 카지노 한글화 클라이언트 개발
- 인도네시아 포커 캡사 수순(Capsa Susun)을
게임화한 캡사 수순 클라이언트 개발

중소 게임 개발사

사원
2009.10 ~ 2015.11

- 캐주얼 게임, 리듬 게임, 2D MO RPG 클라이언트 개발.
상세 이력은 요청 시 건강보험 가입내역으로 제출

Awards & Patents 수상, 특허, 교육

제8회 K-디지털 트레이닝 해커톤 장려상
고용노동부장관상
2026.09

아바타 생성 장치 및 방법
공동발명(5인), 권리자 (주)일루니
2024 ~ 2025 등록

학습자가 선택한 동영상을 학습 콘텐츠로
활용하는 외국어 학습시스템
공동발명(4인), 권리자 (주)티쓰리엔터테인먼트
2020.03

교육

학력

병역

Tech Stack 기술 스택

언어

엔진과 툴

실시간 오디오

AI 모델과 배포

AI 제품 파이프라인

웹과 운영

협업 운영

등록특허 4건, 국가연구개발사업 참여

SAVERS 재난 대피 안내 서비스, Tech Lead. 본선 진출 20개 팀

- KR 10-2652652(2024.03.26) / KR 10-2876336(2025.10.21) / US 12,223,576 B2(2025.02.11)
- 과기정통부 실감콘텐츠핵심기술개발 "문장으로부터의 3차원 동영상 자동 생성 기술" 과제 결과물

- KR 10-2093938(2020.03.20 등록)
- 후속 출원 5건에 피인용

- 코드잇 스프린트 AI 엔지니어 부트캠프 (K-DT 10기), 2026.02 ~ 2026.08 수료
- 부산 게임 아카데미 프로그래밍 과정, 2008.02 ~ 2009.02

- 동의대학교 게임공학 졸업, 2005.03 ~ 2010.03

- 육군 병장 만기 제대, 2000.09 ~ 2002.11

주력 C# / Unity, AI 모델 배포

C#(주력, 멀티스레드), C/C++(llama.cpp C-ABI 래퍼 작성), Objective-C, Python, JavaScript, Lua

Unity(6.3 LTS 포함), Unity Sentis, Visual Studio, Xcode, Android Studio, Android NDK, CMake, llvm-mingw 교차컴파일, Git, SVN

Agora 더블 버퍼링 녹음, Unity Microphone 실시간 버퍼 청크 처리, dB 측정, 파형 출력

PyTorch, ONNX(opset 17), PTQ 정적 양자화(INT8, fbgemm), FP16 경량화, llama.cpp / GGUF, RAG, LangChain / LangGraph, HuggingFace Transformers, IL2CPP / AOT 대응, vLLM, Nvidia Triton, TensorRT, TensorFlow Lite

OpenAPI 계약 우선 설계, 프롬프트 설계와 출력 가드레일, 골든셋 on/off 대조와 LLM 채점 하네스, gpt-image-2 / gpt-5 API 연동, SDXL + IP-Adapter 로컬 탐색

FastAPI, Next.js, TypeScript, Tailwind, Cloudflare Workers / Durable Objects, docker compose, GCP / AWS VM, GitHub Actions, pre-commit(ruff, mypy, pytest), Playwright E2E

AGENTS.md / CLAUDE.md 기반 코드 에이전트 규칙, ADR, 회의록 기반 의사결정, CODEOWNERS

Unity 온디바이스 RAG 앱

개인
2026

- llama.cpp를 C-ABI 래퍼와 P/Invoke로 Unity에 직접 통합.
Android arm64 빌드, IL2CPP AOT 대응(static 콜백)
- KURE-v1 임베딩 모델을 ONNX FP16으로 변환해 2.2GB에서 1.1GB로 경량화. SentencePiece 토큰라이저를 C#으로 포팅
- LangGraph 설계를 C# 상태기계로 이식.
검색 점수 임계값 라우팅과 API 폴백, 골든 Q&A 자동 판정
- Galaxy S25 실기기 검증

AI 모델 경량화, 온디바이스 배포

의료영상 분류 모델(MobileNetV3-Large)
2026

- 3종 포맷 변환 및 배포 적합성 평가
 - PTQ 정적 양자화(INT8)로 모델 용량
16.24MB에서 4.47MB로 압축(3.64배),
ONNX(opset 17) 변환으로 CPU 단건 추론 지연
20.20ms에서 9.40ms로 단축(2.15배)
 - 의료 도메인 원칙에 따라 accuracy 대신
위음성(FN) 최소화를 선택 기준으로 삼아,
val accuracy가 3.4%p 낮지만 FN 0인 체크포인트를 채택
 - 양자화 후 예측 변화 26/624건이 전부 위양성 방향임을 확인,
Recall 1.0과 FN 0 유지 검증
 - ONNX가 INT8보다 빠른 역전 현상을 측정하고
런타임 최적화 차이로 원인 분해

브랜드 스타일 광고 소재 생성 서비스

테크리드, AI 생성/서빙 | 4인
2026.08

- 제품 사진, 제품명, 소구점을 입력하면 인스타그램용 광고
소재(만화형 6칸 또는 단일 이미지)를 만드는 서비스.
이미지 생성 전에 텍스트 시안을 먼저 보여 주고 지정한 부분만 교체
- FastAPI 백엔드, 독립 배포 AI 엔진, React 프론트엔드를
OpenAPI 계약 하나로 결합하고 파이썬 import를
양방향 금지하는 모노레포 설계. GCP GPU VM에 docker compose로 배포
- 만화형을 칸 단위로 생성해 3x2로 합성: 1번 칸을
레퍼런스로 나머지 5칸 병렬 생성. 칸 크기 1152px 정확,
여백 0px (한 장에 6칸 방식은 1101 ~ 1142px, 여백 14 ~ 36px)
- 광고 카피 가이드라인(금지 표현 검출, 프롬프트와 출력 2지점,
검출 시 1회 재생성): 골든셋 26건 x on/off 대조 최종 위반 0건,
실물 19세션 위반 0건
- 카피 사실 일치율 가이드라인 on 1.0 / off 0.9268 (LLM 채점자 1인,
사람 평가 미확인). 단일 광고형 생성 지연 p50 24.05초 / p95 27.05초
- 로컬 이미지 모델(SDXL + IP-Adapter, FLUX, Qwen-Image)을
VRAM, 지연, 한글 렌더링 기준으로 실측해 외부 API 채택 근거 작성
- 팀 커밋 165건으로 최다, ADR 19건 작성
- 저장소 (GitHub, public, MIT) [확인하기](#)

SAVERS 재난 대피 안내 서비스

Tech Lead | 4인
2026.08 ~ 2026.09

- 제8회 K-디지털 트레이닝 해커톤 장려상(고용노동부장관상, 2026.09.04). 본선 진출 20개 팀
- 정부 특보를 받아 재난 취약계층에게 대피소와 경로, 행동지침을 웹푸시로 안내하는 서비스. 판정(정부), 계산(서비스), 전달(PWA) 3층 구조로 자체 위험 판정을 두지 않는 설계
- 시스템 아키텍처와 모듈 간 HTTP 계약(openapi.yaml, 22회 개정) 소유. 보호자 Q&A 검증기 규칙과 30분 페루프 상태 전이 스펙 작성, 코드 프리즈 선언
- 결정 근거 등급(근거 / 조건부 / 비근거)을 AGENTS.md에 정의하고, 확정은 커밋된 회의록만, 구조 결정은 ADR만으로 하도록 저장소 운영
- 최종보고서 A4 64쪽 본문과 Markdown을 PDF로 만드는 2패스 변환기 작성. 본선 기술 질의응답 주도
- 팀 커밋 128건으로 최다
- 저장소 (GitHub, public) [확인하기](#)

PR 사이트와 Ask AI 챗봇

개인
2025 ~ 운영 중

- Next.js static export와 Cloudflare Workers로 구축. Workers AI와 NVIDIA API 기반 챗봇, Turnstile과 Durable Objects rate limit, GitHub Actions로 lint, build, E2E, deploy 자동화
- Lighthouse 접근성 100, 성능 97 ~ 100, SEO 100. 챗봇 응답 약 0.6초. 운영비 0원